

GPU FinOps Lab - Báo Cáo Phân Tích

Họ và tên: Nguyễn Thành Đạt MSSV: 2A202600203 Ngày nộp: 13/05/2026

1. Giới thiệu

1.1. Mục tiêu bài lab

Bài lab GPU FinOps & Cost Optimization giúp sinh viên tiếp cận thực tế các khái niệm và công cụ trong lĩnh vực **FinOps (Financial Operations)** applied to GPU infrastructure. Mục tiêu chính bao gồm:

- Giám sát cluster GPU theo thời gian thực, theo dõi utilization, memory, power, temperature.
- Theo dõi và phân bổ chi phí cho từng workload GPU.
- Quản lý Spot Instances để tối ưu chi phí.
- Cấu hình autoscaling (KEDA-like) dựa trên ngưỡng utilization.
- Phân tích waste và đưa ra khuyến nghị tối ưu chi phí.
- Train model thực tế trên GPU (ResNet-18 + CIFAR-10), so sánh FP32 vs AMP.
- Phân tích chi phí nâng cao: multi-GPU scaling, forecasting, và strategy design.

1.2. Tổng quan về GPU FinOps

FinOps là phương pháp quản lý chi phí cloud, kết hợp giữa kỹ thuật, tài chính và hoạt động kinh doanh. Khi áp dụng cho GPU infrastructure (GPU FinOps), các tổ chức có thể:

- Visibility:** Nhìn thấy chi phí GPU ở mức workload/node.
- Optimization:** Phát hiện waste, underutilization, và tối ưu hóa resource allocation.
- Automation:** Tự động scale up/down dựa trên nhu cầu thực tế.
- Governance:** Đặt budget alerts, kiểm soát chi phí không vượt ngưỡng.

Các công cụ và khái niệm được sử dụng trong lab:

- OpenCost-like tracking:** Phân bổ chi phí theo node, workload.
- KEDA-like autoscaling:** Scale cluster dựa trên GPU utilization.
- Spot Instance Management:** Tận dụng giá spot để giảm 60-70% chi phí.
- NVIDIA pynvml:** Thu thập metrics GPU thời gian thực (utilization, memory, power, temperature).
- Mixed Precision (AMP):** Training tối ưu với half-precision, giảm memory và tăng speed.

2. Phân tích từng phần

Part 1: GPU Cluster Monitoring

Kết quả quan sát được:

Metric	Giá trị
Tổng số GPU	8
GPU đang bận (Busy)	0
GPU rảnh (Idle)	8
Utilization trung bình	8.1%
Memory sử dụng	11.0 / 288.0 GB
Tổng công suất	263 W

Chi tiết các node:

Node	GPU	Type	Util	Memory	Power	Temp
node-00	GPU 0	T4	2.9%	0.7/16.0GB	34W	32°C
node-00	GPU 1	T4	9.1%	2.0/16.0GB	44W	38°C
node-01	GPU 0	A100	1.8%	1.7/80.0GB	34W	42°C
node-01	GPU 1	A100	7.1%	1.3/80.0GB	31W	38°C
node-02	GPU 0	V100	5.3%	1.7/32.0GB	41W	31°C
node-02	GPU 1	V100	14.9%	1.3/32.0GB	32W	36°C
node-03	GPU 0	T4	12.6%	1.2/16.0GB	27W	44°C
node-03	GPU 1	T4	11.3%	1.0/16.0GB	21W	44°C

Insights:

- Tất cả 8 GPU đều đang ở trạng thái idle, utilization trung bình chỉ 8.1% — đây là mức **extremely low utilization**, cho thấy cluster đang không có workload nào chạy.
- Điều này dẫn đến **chi phí waste lớn**: các GPU dù không sử dụng vẫn tiêu tốn điện (263W tổng) và chi phí thuê.
- Các loại GPU đa dạng (T4, A100, V100) phản ánh một cluster GPU thực tế với mixed hardware.

Part 2: Workload Submission & Cost Tracking

Kết quả submit 4 workloads:

Workload	GPU Type	GPUs	Duration	Instance Type
train-resnet-001	T4	1	300s	On-demand
train-bert-002	A100	1	600s	On-demand
inference-api-003	T4	1	120s	Spot
train-llm-004	A100	2	900s	Spot

Sau khi submit:

- Busy GPUs: 5/8
- Utilization tăng lên: **48.0%**

Billing Summary:

Metric	Giá trị
Total Cost	\$1.1949
Total Savings	\$1.2927

Metric	Giá trị
Budget Used	1.2%
Alert Status	OK

Chi phí chi tiết:

Workload	Type	Cost	Savings
train-resnet-001	On-demand	\$0.0292	\$0.0000
train-bert-002	On-demand	\$0.6117	\$0.0000
inference-api-003	Spot	\$0.0035	\$0.0082
train-llm-004	Spot	\$0.5505	\$1.2845

Insights:

- Tổng savings (\$1.2927) vượt tổng cost (\$1.1949) — nhờ việc sử dụng spot instances cho 2 workloads dài.
- Workload train-llm-004 (900s, 2x A100) là nguồn tiết kiệm lớn nhất (\$1.2845) khi dùng spot.
- Billing system hoạt động đúng: phân biệt rõ cost giữa on-demand và spot.

Part 3: Spot Instance Management

Bảng giá Spot vs On-Demand:

GPU Type	On-Demand (\$/hr)	Spot Price (\$/hr)	Discount	Availability
T4	\$0.35	\$0.2225	36.4%	medium
A100	\$3.67	\$2.2878	37.7%	high
V100	\$2.48	\$1.8396	25.8%	medium

Spot Requests:

- Tất cả 3 spot requests được granted:
 - spot-t4-001 (T4)
 - spot-t4-002 (T4)
 - spot-a100-001 (A100)

Spot Preemption Simulation:

- 1 instance bị preempted: spot-t4-002 (chạy 2s với 120s warning)
- Còn lại: 2 instances active

Spot Savings Report:

Metric	Giá trị
Spot Cost	\$0.0007
On-Demand Equivalent	\$0.0024
Total Saved	\$0.0017
Savings Rate	70.0%

Insights:

- Spot instances tiết kiệm 25-38% so với on-demand tùy GPU type.
- A100 có mức discount cao nhất (37.7%), rất có lợi cho các workload training dài.
- Rủi ro preemption cần được xem xét — cần checkpointing và retry logic.
- Savings rate 70% trong mô phỏng cho thấy spot là chiến lược cost optimization hiệu quả nhất.

Part 4: Autoscaling (KEDA-like)

Autoscaling Policy — Before vs After Update:

Parameter	Before	After
scale_up_threshold	80.0%	70.0%
scale_down_threshold	20.0%	25.0%
cooldown_seconds	60	30
max_nodes	8	10
min_nodes	1	2
preferred_gpu_type	T4	T4
cost_aware	True	True

Autoscaler Evaluation (5 cycles):

Cycle	Action	Utilization	Nodes
1	NO_ACTION	48.0%	4→4
2	NO_ACTION	48.0%	4→4
3	NO_ACTION	48.0%	4→4
4	NO_ACTION	48.0%	4→4
5	NO_ACTION	48.0%	4→4

Insights:

- Utilization 48.0% nằm trong ngưỡng [25.0-70.0%] nên autoscaler giữ nguyên 4 nodes — đúng behavior.
- Policy mới nhạy hơn: scale-up ở 70% (thay vì 80%) giúp phản ứng sớm hơn với workload tăng.
- Cooldown giảm từ 60s xuống 30s giúp cluster adaptive nhanh hơn.
- `cost_aware: True` đảm bảo autoscaler ưu tiên T4 (rẻ hơn) khi scale up.

Part 5: Cost Analysis & Optimization (OpenCost-like)

Cost Snapshots (5 lần liên tiếp):

Snapshot	Total Cost	Idle Cost	Waste %
1	\$0.038056	\$0.008833	23.2%
2	\$0.038056	\$0.008833	23.2%
3	\$0.038056	\$0.008833	23.2%
4	\$0.038056	\$0.008833	23.2%
5	\$0.038056	\$0.008833	23.2%

Waste Analysis Report:

Metric	Giá trị
Average Waste	23.2%
Total Idle Cost	\$0.044165
Total Cost	\$0.190280
Potential Monthly Savings	\$2,289.51
Severity	LOW

Optimization Recommendations:

#	Priority	Type	Description	Est. Savings
1	MEDIUM	USE_SPOT	Switch fault-tolerant workloads to spot instances	65.0%
2	LOW	SCHEDULING	Schedule non-urgent training jobs during off-peak hours	20.0%

Insights:

- Waste ở mức 23.2% — khá cao, chủ yếu do GPU idle chưa được released kịp thời.
- Potential monthly savings \$2,289.51 nếu tối ưu hết waste — con số đáng kể cho production.
- Khuyến nghị ưu tiên #1 (USE_SPOT) có savings cao nhất (65%), phù hợp với phân tích Part 3.

Part 6: Visualization

Hai biểu đồ được tạo từ mock data:

- Cost Breakdown Visualization (Cell 16):** 3 subplots phân tích chi phí theo GPU type, workload, và thời gian.
- Time-series Cost Tracking (Cell 17):** Stackplot theo dõi chi phí theo thời gian với waste percentage.

Insights:

- Visualization giúp trực quan hóa dữ liệu chi phí phức tạp thành các biểu đồ dễ hiểu.
- Time-series chart cho thấy waste có xu hướng ổn định (23.2%) qua các snapshots.
- Cost breakdown theo GPU type giúp xác định A100 là nguồn chi phí lớn nhất (đắt nhất per hour).

Part 7: Complete FinOps Workflow

Full workflow thực thi 7 bước end-to-end:

Step	Action	Result
1	Initial cluster state	GPUs: 8, Util: 48.0%, Idle: 3
2	Submit heavy workloads	Util: 68.3%, Busy: 8/8
3	Autoscaler evaluation	NO_ACTION (68.3% within [25.0-70.0%])
4	Cost analysis	\$0.038056/interval, Waste: 0.0%
5	Get recommendations	USE_SPOT (~65%), SCHEDULING (~20%)
6	Apply optimization	Switch to spot → 70.0% savings (\$0.0857)
7	Final billing	Spend: \$1.3640, Saved: \$1.4151, Budget: 1.4%

Insights:

- Workflow đầy đủ thể hiện vòng lặp FinOps: **Observe** → **Analyze** → **Act** → **Optimize**.
- Bước 6 (apply spot) là key driver của savings.
- Total saved (\$1.4151) > total spend (\$1.3640), chứng minh FinOps workflow có ROI positive.

Part 8: Real GPU Training — FP32 vs Mixed Precision (AMP)

GPU Environment:

Property	Value
GPU Name	Tesla T4
Memory	15.6 GB
GPU Type (mapped)	T4
On-Demand Rate	\$0.35/hr
CUDA Version	12.8
Monitoring Library	pynvml (available)

GPU Metrics Diagnostic (Cell 20):

Metric	Value
GPU Utilization	0% (idle)
Memory	472 / 16,106 MB
Power	10.1W
Temperature	42°C

Training Results — FP32 vs AMP:

Metric	FP32 (Baseline)	AMP (Mixed Precision)	Improvement
Total Time	129.8s	70.9s	1.83x faster
Peak Memory	0.82 GB	0.60 GB	0.22 GB saved
Est. Cost	\$0.012619	\$0.006897	\$0.005722 saved
Cost Saving	—	—	45.3%
Avg GPU Util	93.9%	73.7%	—
Avg Power	66.4W	64.1W	—
Avg Temp	68.6°C	76.8°C	—
Max GPU Util	98.0%	90.0%	—
Accuracy (Epoch 3)	53.4%	63.3%	+9.9%

Training Time per Epoch:

Epoch	FP32 Time	AMP Time	Speedup
1	41.4s	24.0s	1.73x
2	42.0s	23.7s	1.77x
3	46.3s	23.2s	2.00x

Extrapolated Savings at Scale:

Scale	FP32 Cost	AMP Cost	Savings
1 day training	\$8.40	\$4.59	\$3.81
1 week training	\$58.80	\$32.14	\$26.66
1 month training	\$252.00	\$137.73	\$114.27

Real GPU Cost Reporting to Gateway:

Workload	Cost	Savings
real-gpu-resnet18-fp32	\$0.012600	\$0.000000
real-gpu-resnet18-amp	\$0.002100	\$0.004800

Final Dashboard (Mock + Real GPU):

Metric	Value
Total Platform Cost	\$1.3640
Total Savings	\$1.4151
Budget Utilization	1.4%
Alert Status	OK

Insights:

- **AMP là game-changer:** 1.83x speedup + 45.3% cost reduction + higher accuracy (63.3% vs 53.4%).
- Memory reduction từ 0.82GB xuống 0.60GB giúp chạy được batch size lớn hơn hoặc model phức tạp hơn trên cùng GPU.
- At scale (1 tháng), AMP tiết kiệm \$114.27 — con số rất significant cho production training jobs.
- GPU telemetry với pynvml hoạt động ổn định, thu thập được đầy đủ metrics.

Part 8.5: Advanced GPU Cost Optimization

8.5.1. Multi-GPU Cost Analysis

GPUs	Scaling Factor	Time (h)	Cost	Cost/Unit	Speedup
1	1.0	2.000	\$0.7000	\$0.7000	1.00x
2	1.8	1.111	\$0.7778	\$0.3889	1.80x
4	3.2	0.625	\$0.8750	\$0.2187	3.20x
8	5.5	0.364	\$1.0182	\$0.1273	5.50x

Optimal: 8x T4 @ \$0.35/hr

Insights:

- Scaling efficiency giảm dần: 1→2 GPU: 1.8x (ideal: 2.0x), 4→8 GPU: chỉ 1.7x thêm.
- **Cost per unit** giảm mạnh: 8 GPU có cost/unit chỉ bằng 18.2% của 1 GPU.
- Điểm hòa vốn (break-even) cho multi-GPU: khi nào time savings > cost overhead của GPU bổ sung.

8.5.2. Project Cost Forecasting

4-Phase ML Project:

Phase	GPU	#GPU	Hours	Base Cost	Uncert%	Range	%Total
Data Preparation	T4	1	40	\$14.00	15%	\$2.10	0%
Model Training	A100	4	120	\$1,761.60	25%	\$440.40	50%

Phase	GPU #	GPU Hours	Base Cost	Uncert%	Range	%Total
Hyperparameter Tuning	A100 8	60	\$1,761.60	30%	\$528.48	50%
Model Evaluation	T4 2	20	\$14.00	10%	\$1.40	0%
BASE TOTAL			\$3,551.20			100%

Confidence Interval Analysis (95% CI, z=1.96, 20% contingency):

Scenario	Cost
Best Case (lower bound)	\$2,202.85
Expected (with contingency)	\$4,261.44
Worst Case (upper bound)	\$5,609.79
Uncertainty Range	±\$1,348.35

Risk Phases: Hyperparameter Tuning (30% uncertainty) và Model Training (25% uncertainty) chiếm 99.9% chi phí dự án.

Insights:

- Model Training + Hyperparameter Tuning chiếm 99.9% chi phí → tập trung tối ưu ở đây.
- Contingency 20% là hợp lý vì uncertainty của ML projects rất cao.
- Phases nhỏ (Data Preparation, Model Evaluation) chỉ chiếm 0.01% nên có thể bỏ qua cost optimization.

8.5.3. Optimization Opportunity Analysis

Baseline Cost: \$1,468.00 (4x A100, 100h)

#	Strategy	Savings %	Savings \$	Effort	Risk	Priority	Cumul. \$
1	Switch to Mixed Precision (AMP)	25%	\$367.00	LOW	LOW	0.2500	\$367.00
2	Optimize Batch Size	15%	\$220.20	LOW	LOW	0.1500	\$587.20
3	Implement Early Stopping	20%	\$293.60	MEDIUM	LOW	0.0667	\$880.80
4	Use Spot Instances	60%	\$880.80	MEDIUM	HIGH	0.0400	\$1,761.60
5	Switch to More Efficient GPU Type	40%	\$587.20	HIGH	MEDIUM	0.0190	\$2,348.80

Optimization Roadmap:

Category	Strategies
Quick Wins (LOW effort, LOW risk)	Switch to AMP, Optimize Batch Size
Big Bets (HIGH effort, HIGH savings)	Switch to More Efficient GPU Type
High Risk + High Savings	Use Spot Instances

Total cumulative savings: \$2,348.80 (160% combined savings rate)

Insights:

- Priority score = (savings_pct / effort) * (1 / risk) → đánh giá khách quan giá trị của mỗi strategy.
- Quick wins (AMP + Batch Size) cho \$587.20 savings với LOW effort — nên làm trước.
- Spot Instances có savings cao nhất (60%) nhưng HIGH risk → cần checkpointing.
- Combined savings rate 160% nghĩa là có thể tiết kiệm nhiều hơn baseline cost nếu áp dụng tất cả strategies.

8.5.4. Challenge Exercise — LLM Fine-tuning Strategy

Challenge Scenario:

Parameter	Value
Project	Large Language Model Fine-tuning
Training Duration	200h
GPU Type	A100
Initial GPU Count	8
Precision	FP32
Instance Type	On-demand
Budget	\$5,000

Optimization Steps:

Step	Description	Result
STEP 1	Baseline cost	\$5,872.00 (OVER budget)
STEP 2	Optimal GPU config	8x A100 (under budget)
STEP 3	Selected optimizations (5 strategies)	AMP + Batch Size + Early Stopping + Spot + Gradient Checkpointing
STEP 4	Forecast (95% CI)	Expected: \$287.08, Best: \$243.67, Worst: \$343.36
STEP 5	Constraint verification	Budget: PASS , Deadline: PASS

Final Strategy Summary:

Metric	Value
Baseline	\$5,872.00
Optimized	\$287.08
Total Savings	\$5,584.92 (95.1%)
GPU Config	16x A100 (9.0x speedup)
Budget Check	PASS
Deadline Check	PASS

Insights:

- Baseline vượt budget \$872 — chứng minh tầm quan trọng của FinOps planning.
- Chiến lược kết hợp 5 optimizations giảm chi phí 95.1%, xuống chỉ còn \$287.08.
- Gradient Checkpointing (tiết kiệm 18%) giúp giảm memory, cho phép batch size lớn hơn.
- Tất cả constraints đều PASS, strategy có tính khả thi cao trong thực tế.

3. Kết luận và học hỏi

3.1. Những kỹ năng FinOps đã học

Qua bài lab, các kỹ năng và kiến thức FinOps quan trọng đã được thực hành:

- GPU Monitoring:** Sử dụng pynvml để thu thập real-time GPU metrics (utilization, memory, power, temperature).
- Cost Allocation:** Phân bổ chi phí GPU theo workload và node, hiểu được cost per GPU-hour.
- Spot Instance Strategy:** Đánh giá trade-off giữa savings (25-70%) và reliability (preemption risk).
- Autoscaling Policy Design:** Cấu hình ngưỡng scale-up/scale-down phù hợp với workload pattern.
- Waste Analysis:** Xác định và định lượng waste từ idle resources (23.2% trong bài lab).
- Mixed Precision Training (AMP):** Tối ưu training với PyTorch AMP — kỹ năng quan trọng cho ML practitioners.
- Multi-GPU Scaling Analysis:** Hiểu scaling efficiency và cost-per-unit khi parallelize training.
- Project Cost Forecasting:** Sử dụng confidence intervals và contingency buffer cho ML project budgets.
- Optimization Prioritization:** Đánh giá và rank strategies dựa trên savings/effort/risk ratio.
- End-to-end FinOps Workflow:** Kết hợp tất cả các thành phần thành một continuous improvement loop.

3.2. Các chiến lược cost optimization hiệu quả

Top 5 strategies từ kết quả lab:

Rank	Strategy	Avg Savings	Effort	Risk	Recommendation
1	Mixed Precision (AMP)	45.3%	LOW	LOW	Always use
2	Spot Instances	60-70%	MEDIUM	HIGH	With checkpointing
3	Early Stopping	20%	MEDIUM	LOW	Implement always
4	Off-peak Scheduling	20%	LOW	LOW	Batch jobs
5	Multi-GPU Optimization	Varies	MEDIUM	LOW	For large training

Key findings:

- AMP là chiến lược có ROI cao nhất:** Không tăng risk, LOW effort, nhưng tiết kiệm 45.3% cost + speedup 1.83x + better accuracy.
- Spot + Checkpointing là cặp đôi hoàn hảo:** Spot tiết kiệm 60-70% nhưng rủi ro preemption. Kết hợp checkpointing giảm rủi ro.
- Quick wins quan trọng hơn big bets ban đầu:** AMP + Batch Size + Early Stopping tiết kiệm \$587.20 với LOW effort, có thể bắt đầu ngay.
- Cost forecasting là bắt buộc:** ML project costs có uncertainty cao (30%), cần contingency buffer 20-30%.

3.3. Ứng dụng thực tế trong projects

- ML Training Pipelines:** Áp dụng AMP cho mọi training job — đây là best practice industry-standard với PyTorch.
- Production GPU Clusters:** Implement autoscaling với cost_aware mode để tránh over-provisioning.

- 3. **Budget Planning:** Sử dụng confidence intervals và contingency buffer khi lập budget cho ML projects.
- 4. **Spot/Preemptible Instances:** Dùng cho batch training, experiments, hyperparameter search — những job có thể restart.
- 5. **Multi-GPU Training:** Đánh giá scaling efficiency trước khi scale, tránh waste từ parallelization overhead.
- 6. **Continuous Monitoring:** Thiết lập budget alerts và waste monitoring như phần standard của MLOps pipeline.

3.4. Tổng kết con số

Metric	Value
Total Parts hoàn thành	8.5 / 8.5
Mock cluster GPUs monitored	8
Spot savings achieved	70.0%
Cost waste identified	23.2%
Monthly waste potential	\$2,289.51
AMP speedup	1.83x
AMP cost reduction	45.3%
AMP accuracy improvement	+9.9%
Challenge savings (LLM fine-tuning)	95.1%
Optimization strategies analyzed	5

Bài lab đã cung cấp một cái nhìn toàn diện về GPU FinOps — từ monitoring cơ bản đến chiến lược optimization nâng cao — và chứng minh rằng với kiến thức và công cụ đúng, có thể giảm đáng kể chi phí GPU infrastructure mà không ảnh hưởng (thậm chí cải thiện) performance và accuracy của ML workloads.